

# Implementasi Metode Long Short Term Memory (LSTM) untuk Memprediksi Harga Bahan Pokok Nasional

Jumina Cahyani<sup>a1</sup>, Syamsul Mujahidin<sup>a2</sup>, Tegar Palyus Fiqar<sup>a3</sup>

<sup>a1, a2, a3</sup>Program Studi Informatika, Institut Teknologi Kalimantan

Jl. Soekarno Hatta KM. 15, Karang Joang, Balikpapan, Kalimantan Timur, 76127, Indonesia

<sup>1</sup>juminacahyani16@gmail.com

<sup>2</sup>syamsul@lecturer.itk.ac.id

<sup>3</sup>tegar@lecturer.itk.ac.id

## Abstrak

Ketidakstabilan perekonomian di Indonesia saat pandemi menyebabkan harga bahan pokok nasional mengalami fluktuasi. Salah satu upaya untuk menjaga harga agar tetap stabil adalah dengan melakukan observasi dan memprediksi harga di masa yang akan datang. Harga bahan pokok nasional berubah setiap hari sehingga data bersifat *non-linear* dan berbasis deret waktu. Salah satu metode yang dapat digunakan untuk prediksi data berbasis deret waktu adalah metode *Recurrent Neural Network* (RNN). Namun demikian, metode RNN memiliki kelemahan, yaitu adanya permasalahan *vanishing gradient* atau hilangnya nilai gradien saat pembaruan bobot. Metode *Long Short Term Memory* (LSTM) mampu mengatasi permasalahan pada metode RNN. Oleh karena itu, metode LSTM digunakan untuk memprediksi harga bahan pokok nasional. Terdapat empat harga bahan pokok yang dipilih berdasarkan uji normalitas data, yaitu harga daging ayam ras segar, harga beras kualitas bawah II, harga minyak goreng, dan harga minyak goreng curah. Untuk pengoptimalan hasil prediksi digunakan metode optimasi sebagai skenario uji coba, yaitu metode *Adaptive Gradient* (ADAGRAD), *Adaptive Moment Gradient* (ADAM), *Root Mean Square Error* (RMSProp). Berdasarkan uji coba dengan ketiga metode optimasi tersebut didapatkan model terbaik pada harga beras kualitas bawah II yaitu menggunakan ADAM dengan nilai evaluasi RMSE sebesar 0.0492 dan *R2 Score* sebesar 0.8852. Pada harga daging ayam didapatkan model terbaik menggunakan ADAM dengan nilai evaluasi RMSE sebesar 0.0937 dan *R2 Score* sebesar 0.5949. Pada harga minyak goreng didapatkan model terbaik menggunakan RMSProp dengan nilai evaluasi RMSE sebesar 0.0313 dan *R2 Score* sebesar 0.7492. Sedangkan pada harga minyak goreng curah diperoleh model terbaik menggunakan ADAM dengan nilai evaluasi RMSE sebesar 0.0531 dan *R2 Score* sebesar 0.5308.

**Kata kunci:** Deret Waktu, Harga Bahan Pokok Nasional, *Long Short Term Memory* (LSTM), Prediksi

## Abstract

*The Indonesian economics is unstable during pandemic and its cause the fluctuation of national main food price. One of way to keep those stable national main food price is observed and predict the feature price. The national main food price change everydat, so the dataset is time series based and non-linear. One of method that can used to predict the time series based is Recurrent Neural Network (RNN). However, the RNN method have vanishing gradient problem while update the gradient. Long Short Term Memory (LSTM) method can solve the RNN problem. Because of that, the LSTM method is used to predict the feature national main food price. There are four national main food price that chosen based on dataset trials, they are chicken meat price, low quality rice II, cooking oil, and unlabelled cooking oil. To optimize the predict result used optimizer as experiment scenario, there are Adaptive Gradient (ADAGRAD), Adaptive Moment Gradient (ADAM), Root Mean Square Error (RMSProp). Based on those optimizer, the result of low quality rice II is used ADAM optimizer and the evaluation of RMSE is 0.0492 and R2 Score is 0.8852. The result for predict the chicken meat price is obtained the best model with ADAM and the evaluation of RMSE is 0.0937 and R2 Score is 0.594. The best model for predict cooking oil is used RMSProp and the evaluation of RMSE is 0.0313 and R2 Score is 0.7492. Meanwhile the best model to predict the unlabelled cooking oil is used ADAM optimizer and the evaluation of RMSE is 0.0531 and R2 Score is 0.5308.*

**Keywords:** Long Short Term Memory (LSTM), National Main Food Price, Prediction, Time Series.

## I. PENDAHULUAN

Ketidakstabilan perekonomian di Indonesia yang disebabkan karena pandemi, ditandai dengan adanya fluktuasi terhadap harga bahan pokok. Penyebab utama terjadinya fluktuasi pada harga bahan pokok tersebut adalah pembatasan wilayah selama pandemi *Covid-19* dan faktor lainnya [1]. Fenomena fluktuasi harga bahan pokok dapat diantisipasi dengan beberapa upaya salah satunya yaitu mengkaji dan melakukan prediksi terhadap harga bahan pokok di masa yang akan datang. Prediksi terhadap harga bahan pokok ini dapat digunakan sebagai cara untuk memutuskan kebijakan agar harga tetap terjaga kestabilannya.

Harga bahan pokok berubah setiap harinya. Sehingga dalam memprediksi harga bahan pokok dapat menggunakan deret waktu. Data deret waktu merupakan sekumpulan data yang dirangkum dalam jangka waktu tertentu, seperti setiap bulan, setiap tahun, setiap hari dan lain sebagainya [2]. Prediksi data deret waktu berarti bahwa memprediksi peristiwa di masa yang akan datang dengan menggali pola data sebelumnya. Dalam memprediksi data deret waktu dapat menggunakan beberapa metode antara lain yaitu metode *Exponential Smoothing*, *Autoregressive Integrated Moving Average* (ARIMA), *Support Vector Machine* (SVM), *Multilayer Perceptron* (MLP), *Recurrent Neural Network* (RNN) dan *Long Short Term Memory* (LSTM).

Beberapa metode untuk memprediksi data deret waktu sudah diterapkan pada penelitian sebelumnya yaitu penelitian tentang prediksi harga cabai menggunakan metode deret waktu ARIMA dilakukan oleh Nur Hadiansyah, (2017)[3]. Pada penelitian tersebut dijelaskan bahwa metode ARIMA memiliki kelemahan yaitu hanya bisa memprediksi untuk data deret waktu jangka pendek. Metode ARIMA akan menghasilkan akurasi yang kurang baik dan cenderung datar dalam melakukan prediksi data deret waktu jangka panjang. Hal ini berbeda dengan metode LSTM, pada penelitian sebelumnya yang dilakukan oleh [4] dalam memprediksi harga minyak dunia menggunakan metode LSTM, didapatkan hasil *error* yang sangat kecil dan memiliki kinerja yang cukup baik. Penelitian tersebut melakukan eksperimen menggunakan parameter-parameter yang berbeda dalam memprediksi harga minyak dunia. Model terbaik mendapatkan hasil nilai *error* paling rendah yaitu sebesar 0.0186. Penelitian lainnya juga memprediksi harga saham Telkom dengan cara membandingkan metode ARIMA dengan LSTM.

Hasil yang diperoleh yaitu metode LSTM mendapatkan hasil akurasi yang lebih baik daripada metode ARIMA [5]. Pada metode LSTM memperoleh hasil nilai *error* saat *training* dan *testing* yaitu sebesar 0.01, sedangkan pada metode ARIMA menghasilkan nilai *error* yang lebih besar yaitu 0.0245.

Pada data deret waktu dapat dibagi menjadi deret waktu jangka panjang dan jangka pendek. Prediksi data jangka pendek ialah prediksi yang dilakukan pada data dengan deret waktu yang akan datang dalam jangka waktu yang cukup singkat, contohnya seperti 30 hari kedepan. Sedangkan prediksi data jangka panjang berarti bahwa

data yang diprediksi dalam waktu yang lama, seperti 100 hari kedepan. Pada penelitian terdahulu dalam memprediksi harga beras dalam kurun waktu 6 bulan kedepan dengan menerapkan metode LSTM, diperoleh hasil akurasi yang tinggi [6]. Hasil prediksi yang didapatkan juga tidak memiliki perbandingan yang cukup jauh dengan data asli.

Selain digunakan pada data jangka panjang, metode LSTM memiliki memori untuk menyimpan informasi yang akan digunakan kembali pada proses perhitungan untuk *gate* selanjutnya. Metode LSTM ialah metode yang dikembangkan berdasarkan permasalahan yang muncul pada metode RNN, yaitu *gradient* yang hilang. Nilai *gradien* yang digunakan untuk memperbarui bobot berada pada kondisi hampir 0 bahkan hilang [5]. Bobot tidak dapat diperbarui untuk proses berikutnya apabila nilai *gradien* hilang.

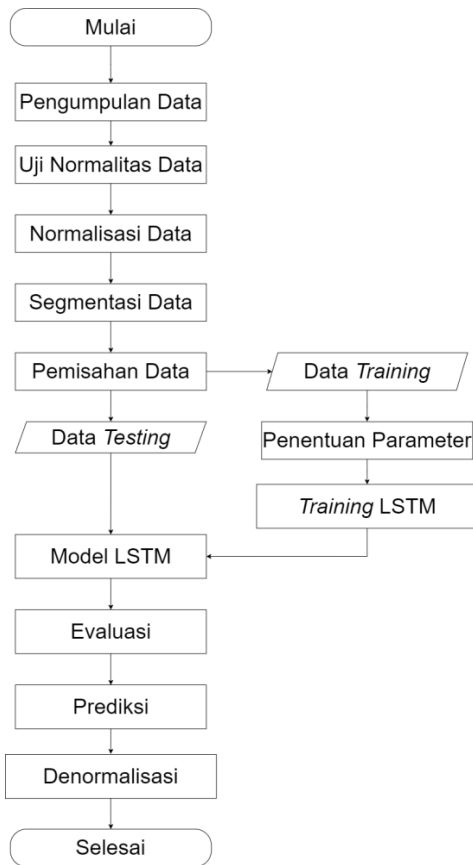
Metode LSTM digunakan pada penelitian ini untuk memprediksi harga bahan pokok nasional. Tujuan dilakukannya penelitian ini adalah untuk mendapati nilai akurasi pada prediksi harga bahan pokok nasional dan mengetahui performa antara metode RNN dan LSTM dalam memprediksi harga bahan pokok nasional.

## II. METODOLOGI PENELITIAN

Penelitian ini melalui beberapa proses untuk mendapatkan hasil prediksi harga bahan pokok beberapa hari kedepan. Proses pertama yang dilakukan adalah melakukan studi literatur yang memiliki kaitan dengan deret waktu, *data science*, pembelajaran mesin, dan statistika. Literatur tersebut dijadikan sebagai acuan dalam melakukan penelitian. Proses yang kedua yaitu *preprocessing data* yang terdiri dari beberapa proses antara lain pengumpulan data, uji normalitas data, normalisasi data dan segmentasi data. Data didapatkan melalui *website* [hargapangan.id](http://hargapangan.id) yang merupakan Pusat Informasi Harga Pangan Strategis Nasional (PIHPSN). Data yang diambil pada tanggal 2 Januari 2018 – 9 September 2021. Data harga bahan pokok yang didapatkan harus dipilih berdasarkan normalitas data tersebut. Pada penelitian ini menggunakan distribusi normal untuk mengetahui kenormalan data. Setelah itu, data di normalisasi kembali menggunakan metode *min max* untuk mengubah skala harga menjadi 0-1. Tahapan selanjutnya yaitu melakukan segmentasi data dengan cara *sliding window* untuk memudahkan model dalam melakukan prediksi. Data yang telah melalui tahapan segmentasi akan dipisah menjadi data *training* dan data *testing*. Model melakukan pembelajaran menggunakan data *training* sedangkan data *testing* digunakan untuk menguji model hasil *training*. Proses atau alur pada penelitian disajikan pada Gambar 1.

### A. Pengumpulan Data

Data harga bahan pokok di Indonesia dikumpulkan melalui *website* [hargapangan.id](http://hargapangan.id) yang merupakan Pusat Informasi Harga Pangan Strategis Nasional (PIHPSN). *Website* tersebut dikelola langsung oleh Bank Indonesia untuk menyediakan informasi secara akurat mengenai harga komoditas pangan di Indonesia.



Gambar 1. Diagram Alir Penelitian

Data yang dikumpulkan sebanyak 903, mulai dari tanggal 2 Januari 2018 – 9 September 2021. Data yang dikumpulkan berupa 32 harga komoditas pangan di Indonesia. Akan tetapi pada penelitian hanya menggunakan data harga komoditas pangan yang memiliki data normal. Untuk mengetahui kenormalan data tersebut, dapat melalui uji normalitas data melalui distribusi normal.

### B. Uji Normalitas Data

Tahap pertama pada *preprocessing* data adalah uji normalitas untuk tiap harga bahan pokok. Uji normalitas data ini bertujuan untuk mengetahui kenormalan data yang ditandai dengan kurva distribusi yang berbentuk seperti lonceng. Distribusi normal ini bertujuan untuk memilih harga bahan pokok yang layak untuk diprediksi. Sehingga prediksi hanya dilakukan untuk harga bahan pokok yang memiliki kurva normal.

Uji normalitas data dengan distribusi normal ini menggunakan nilai rata-rata dan deviasi standar. Data yang normal adalah saat kurva lonceng berdistribusi secara merata baik dari sebelah kiri maupun kanan. Kurva distribusi normal dapat dicari menggunakan persamaan 1 [7].

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, -\infty \leq x \leq \infty \quad (1)$$

Dimana  $f(x)$  adalah fungsi distribusi normal,  $\sigma$  adalah deviasi standar, dan  $\mu$  adalah rata-rata dari data. Untuk mendapatkan nilai rata-rata dari data dapat

menggunakan persamaan 2. Sedangkan untuk mencari nilai deviasi standar dapat menggunakan persamaan 3 [8].

$$\hat{x} = \frac{\sum x_i}{n} \quad (2)$$

Dimana  $\hat{x}$  adalah nilai rata-rata dari kumpulan data,  $x_i$  adalah data ke- $i$  dan  $n$  adalah banyaknya data.

$$s = \sqrt{\frac{\sum (x_i - \hat{x})^2}{n-1}} \quad (3)$$

Dimana  $s$  adalah deviasi standar, yang diperoleh dengan akar dari pembagian antara jumlah kuadrat selisih data ke- $i$  dan rata-rata dengan banyaknya data dikurangi 1.

### C. Normalisasi


Normalisasi merupakan proses mengubah skala data menjadi 0-1. Proses normalisasi pada penelitian ini menggunakan metode *min max*. Metode *min max* diperoleh dengan membagi hasil pengurangan dari data ke- $i$  dan data terkecil dengan hasil pengurangan dari data terbesar dan data terkecil. Rumus dari metode *min max* dapat dilihat pada persamaan 4.

$$x_{norm} = \frac{x_i - x_{min}}{x_{max} - x_{min}} \quad (4)$$

Dimana  $x_{norm}$  adalah data yang telah di normalisasi dalam skala 0-1,  $x_i$  adalah data ke- $i$ ,  $x_{min}$  adalah data terkecil, dan  $x_{max}$  adalah data terbesar.

### D. Segmentasi

Segmentasi adalah proses penentuan untuk variabel dependen dan variabel independen berdasarkan jumlah *timestep* [9]. Pada penelitian ini menggunakan *timestep* sebanyak 7. Pada Gambar 2 merupakan proses segmentasi data.



Gambar 2. Segmentasi Data

Data pertama yang telah melalui proses segmentasi merupakan data ke-1 sampai dengan data ke-7, data kedua merupakan data ke-2 sampai dengan data ke-8, dan begitu juga seterusnya hingga data terakhir.

### E. Pemisahan Data

Langkah selanjutnya yaitu melakukan pemisahan data menjadi data latih dan data uji. Tujuan pemisahan data ini adalah untuk melatih dan menguji model. Banyaknya data latih dan data uji pada penelitian ini sebanyak 80%:20%.

### F. Penentuan Parameter

Proses yang dilakukan sebelum melatih model adalah dengan menentukan parameter-parameter yang diperlukan model LSTM. Parameter yang digunakan antara lain yaitu banyaknya *batch size*, *learning rate*, jumlah *epoch*, jumlah *layer LSTM*, dan bobot serta bias. Bobot awal pada tiap *gate LSTM* telah ditentukan secara acak oleh *library Tensorflow*. Nilai bobot dan bias awal diperbarui untuk mencapai *loss function* yang berada pada lokal minima.

Oleh karena itu, pada penelitian ini menerapkan beberapa percobaan pada penggunaan algoritma optimasi untuk mengoptimalkan model. Percobaan dilakukan pada 3 metode optimasi yaitu *Adaptive Moment Gradient* (ADAM), *Adaptive Gradient* (AdaGrad), dan *Root Mean Square Propagation* (RMSProp).

#### 1) AdaGrad (Adaptive Gradient)

AdaGrad merupakan metode optimasi yang dapat memperbaiki kelemahan pada *Stochastic Gradient Descent* (SGD). AdaGrad menggunakan nilai *learning rate* pada tiap parameter, sehingga dikatakan sebagai *Adaptive Moment Algorithm* [10]. *Learning rate* yang digunakan AdaGrad pada parameter  $\theta_i$  untuk *timestep*  $t$ , sehingga untuk mendapatkan nilai gradien dapat menggunakan persamaan (5) [11].

$$g_{t,i} = \nabla_{\theta_i} J(\theta_{t,i}) \quad (5)$$

Jika algoritma SGD menggunakan *learning rate* yang sama untuk tiap paramter dalam memperbauri bobot, maka dalam AdaGrad mengubah *learning rate* awal  $\mu$  pada parameter  $\theta_i$  untuk tiap *timestep*  $t$  berlandaskan pada akar dari gradien sebelumnya yaitu  $G_{t,i}$ .

$$\theta_{t+1,i} = \theta_{t,i} - \frac{\mu}{\sqrt{G_{t,i} + \epsilon}} \cdot g_{t,i} \quad (6)$$

Dimana  $\epsilon$  adalah suatu kuantitas yang diterapkan untuk mencegah pembagian dengan angka 0 dan  $G_{t,i}$  didapatkan menggunakan persamaan (7).

$$G_{t,i} = \sum_t \left( \frac{\partial}{\partial \theta_{i,t}} \right)^2 \quad (7)$$

#### 2) RMSProp (Root Mean Square Propagation)

Kelemahan pada algoritma AdaGrad dalam menurunkan nilai *leanring rate* dan menjaga nilai *mini-batch gradient* diperbaiki dengan adanya algoritma RMSProp [12]. Pada tiap algoritma optimasi bertujuan untuk mencapai nilai konvergensi secara cepat, begitupula pada algoritma RMSProp. RMSProp menggunakan nilai rata-rata dari gradien sebelumnya dan gradien saat ini secara berturut-turut [13]. RMSProp menggunakan nilai rata-rata  $G_{t,i}$  dalam menurunkan nilai *learning rate*  $\mu$  seperti terlihat pada persamaan (8) [14].

$$\theta_{t+1,i} = \theta_{t,i} - \frac{\mu}{\sqrt{E[G_{t,i}] + \epsilon}} \cdot g_{t,i} \quad (8)$$

Dimana  $E[G_{t,i}]$  adalah rata-rata dari nilai gradien sebelumnya  $G_{t-1,i}$  dan gradien saat ini untuk iterasi ke  $t$ . Nilai rata-rata gradien diperoleh menggunakan persamaan (9) yang mana nilai gradien diatur oleh  $\lambda$  dengan nilai *default* sebesar 0,9.

$$E[G_{t,i}] = \lambda E[G_{t-1,i}] + (1 - \lambda) \left( \frac{\partial}{\partial \theta_{i,t}} \right)^2 \quad (9)$$

#### 3) ADAM (Adaptive Moment Gradient)

ADAM adalah salah satu algoritma optimasi terbaru yang dikembangkan oleh Diederik P. Kingma dan Jimmy Lei Ba pada tahun 2015. ADAM menggabungkan algoritma AdaGrad dan RMSProp dalam mengadaptasi

*learning rate* berdasarkan dua parameter yang berbeda. Parameter tersebut merupakan estimasi pada momentum pertama dan momentum kedua [15]. Estimasi pada momentum pertama  $m_{i,t}$  menggunakan nilai  $\beta_1$  dengan nilai *default* sebesar 0,9. Sedangkan pada estimasi momentum kedua  $v_{i,t}$  menggunakan nilai  $\beta_2$  dengan nilai *default* sebesar 0,999.

$$m_{i,t} = \beta_{1,t} m_{t-1} + (1 - \beta_{1,t}) g_t \quad (10)$$

$$v_{i,t} = \beta_{2,t} v_{t-1} + (1 - \beta_{2,t}) g_t^2 \quad (11)$$


Nilai awal pada gradien yang diatur dengan nilai 0 menyebabkan nilai pada estimasi momentum pertama  $m_{i,t}$  dan estimasi momentum kedua  $v_{i,t}$  bias ke 0.

Sehingga berdasarkan nilai momentum pertama dan kedua yang didapatkan, maka pembaruan bobot menggunakan ADAM dapat menggunakan persamaan (14).

$$\theta_{i,t} = \theta_{i,t-1} - \frac{\mu}{\sqrt{v_{i,t} + \epsilon}} \cdot \hat{m}_{i,t} \quad (14)$$

#### G. Pelatihan Model

Model dilatih menggunakan beberapa percobaan yang diterapkan bersamaan pada metode LSTM untuk mendapatkan model yang terbaik dalam memprediksi harga bahan pokok. Metode LSTM merupakan metode yang dikembangkan untuk memperbaiki adanya permasalahan *vanishing gradient* pada metode (*Reccurent Neural Network*) RNN. Metode LSTM memiliki arsitektur yang hampir mirip dengan metode RNN, yang membedakan adalah pada proses *hidden state* [9]. Proses *hidden state* pada LSTM melalui 4 *gate* yaitu *forget gate*, *input gate*, *cell state* dan *output gate*.



Gambar 3. Arsitektur LSTM

Tiap *gate* menggunakan nilai masukan  $x_t$  dan nilai *hidden state* pada *timestep* sebelumnya  $h_{t-1}$  dengan nilai bobot dan bias yang telah ditentukan diawal. *Forget gate* adalah *gate* pertama yang dilalui oleh masukan yang menggunakan fungsi aktivasi *sigmoid*. Nilai *forget gate* diperoleh menggunakan persamaan (15).

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (15)$$

Dimana  $f_t$  adalah *forget gate*,  $\sigma$  adalah fungsi aktivasi *sigmoid*,  $W_f$  adalah bobot pada *forget gate*,  $h_{t-1}$  adalah nilai *hidden state* pada *timestep* sebelumnya,  $x_t$  adalah masukan, dan  $b_f$  adalah nilai bias pada *forget gate*.



Proses kedua pada *hidden state* adalah menghitung nilai *input gate*. Sama seperti nilai *forget gate*, *input gate* ( $i_t$ ) juga memerlukan nilai masukan ( $x_t$ ), bobot ( $W_i$ ), bias ( $b_i$ ), dan nilai pada *hidden state* sebelumnya  $h_{t-1}$ . *Input gate* diperoleh menggunakan fungsi aktivasi *sigmoid* ( $\sigma$ ) seperti pada persamaan (16).

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (16)$$

Pada *input gate* masih terdapat satu proses, yaitu menghitung nilai kandidat *cell state* baru. Nilai kandidat *cell state* baru  $\tilde{C}_t$  diperoleh menggunakan fungsi aktivasi *tanh* seperti terlihat pada persamaan (17).

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (17)$$

Setelah didapatkan nilai *forget gate*, *input gate*, dan kandidat *cell state* baru, maka nilai *cell state*  $C_t$  dapat dicari dengan menjumlahkan hasil perkalian *forget gate*  $f_t$  dan *cell state* sebelumnya  $C_{t-1}$  dengan hasil perkalian *input gate*  $i_t$  dengan kandidat *cell state* baru  $\tilde{C}_t$  menggunakan persamaan (18).

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (18)$$

Proses selanjutnya yaitu pada *output gate* yang menggunakan fungsi aktivasi *sigmoid*. Nilai *output gate* digunakan untuk menghasilkan nilai *hidden state* baru bersama dengan nilai *cell state*. *Output gate* diperoleh menggunakan persamaan (19).

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (19)$$

Nilai *output gate* yang didapatkan akan digunakan sebagai nilai keluaran *hidden state* menggunakan fungsi *tanh*. Nilai *hidden state* diperoleh dengan mengalikan nilai *output gate* dan *cell state* yang telah melalui proses fungsi *tanh*, seperti terlihat pada persamaan (20).

$$h_t = o_t * \tanh(C_t) \quad (20)$$

#### H. Evaluasi

Model yang diperoleh berdasarkan pelatihan menggunakan metode LSTM, dievaluasi menggunakan *Root Mean Square Error* (RMSE) dan *R2 Score*. RMSE merupakan hasil akar dari kuadrat rata-rata selisih antara data aktual dengan data prediksi [16].

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (21)$$

Dimana  $n$  adalah banyaknya data,  $\hat{y}_i$  adalah data prediksi dan  $y_i$  adalah data aktual. Sedangkan *r2 score* diperoleh dengan cara membagi *varians pada model* dengan total *varians* [17].

$$r2 \text{ score} = \frac{\text{varians pada model}}{\text{total varians}} \quad (22)$$

Dimana *varians pada model* diperoleh dengan menjumlahkan total kuadrat dari selisih antara data prediksi  $\hat{y}_i$  dengan nilai rata-rata pada data.

$$\text{varians pada model} = \sum (\hat{y}_i - y_{rata-rata})^2 \quad (23)$$

Sedangkan total *varians* diperoleh dengan menjumlahkan total kuadrat selisih antara data aktual  $y$  dengan rata-rata pada data.

$$\text{varians pada model} = \sum (y_i - y_{rata-rata})^2 \quad (24)$$

#### I. Prediksi

Prediksi pada harga bahan pokok yang dipilih menggunakan model yang memiliki hasil evaluasi terbaik baik pada saat pelatihan maupun saat pengujian. Prediksi dilakukan untuk 5 hari kedepan.

Dalam melakukan prediksi, diperlukan data sebelumnya. Banyaknya data sebelumnya berdasarkan banyaknya *timestep* yang digunakan. Apabila *timestep* yang digunakan sebanyak 7, maka data untuk memprediksi 5 hari kedepan membutuhkan data harga bahan pokok 7 hari sebelumnya.

#### J. Denormalisasi

Denormalisasi merupakan proses untuk mengembalikan data menjadi skala awal. Denormalisasi dilakukan dengan menurunkan rumus dari persamaan *min max*. Persamaan (25) merupakan rumus turunan dari *min max* yang digunakan untuk denormalisasi.

$$d_i = (n_i) (X_{max} - X_{min}) + \left( \frac{2(X_{min})}{2} \right) \quad (25)$$

Dimana  $d_i$  merupakan data ke- $i$  hasil denormalisasi,  $n_i$  adalah data normalisasi ke- $i$ ,  $X_{max}$  merupakan data terbesar pada data,  $X_{min}$  merupakan data terendah pada data.

### III. HASIL DAN PEMBAHASAN

Hasil yang diperoleh pada penelitian ini berdasarkan pada percobaan yang dilakukan pada beberapa metode optimasi dan parameter seperti *batch size*, *learning rate*, *LSTM layer* dan lainnya.

#### A. Pengumpulan Dataset

*Dataset* yang telah dikumpulkan terdapat 32 atribut yang merupakan harga bahan pokok nasional dengan total data sebanyak 903 data. Pada Gambar 4 merupakan tampilan hasil pengumpulan *dataset*. Akan tetapi 31 harga bahan pokok tersebut akan melalui proses pemilihan melalui uji normalitas data pada bagian *preprocessing dataset*. Hal ini bertujuan untuk mengetahui karakteristik data sebelum masuk pada proses prediksi harga bahan pokok untuk 5 hari kedepan.

Tanggal	Beras	Beras	Beras	Beras	Beras	Beras	Beras	Daging	Ayam	Ayam	Cabai	Cabai	Cabai	Cabai	Minyak	Minyak	Minyak
	Kualitas	Kualitas	Kualitas	Kualitas	Kualitas	Kualitas	Kualitas	Ayam	Ras	Ras	Rawit	Rawit	Rawit	Rawit	Goreng	Goreng	Goreng
	Bawah	Bawah	Medium	Medium	Super I	Super II	Super II	Segar	Segar	Segar	Hijau	Hijau	Hijau	Merah	Kemaskan	Kemaskan	Kemaskan
															1	2	
0	2/12/2018	11750	10650	10300	11050	11700	13650	12600	34800	34800	44350	39900	40800	13000	11950	14950	14300
1	3/1/2018	11750	10650	10350	11050	11700	13650	12600	34750	34750	45000	41000	40550	13050	12000	14950	14300
2	4/1/2018	11750	10700	10350	11900	11750	13100	12600	34400	34400	45550	41400	40550	13650	12000	14950	14300
3	5/1/2018	11800	10700	10350	11900	11750	13100	12600	34550	34550	45500	41700	40350	13000	12000	14950	14300
4	8/1/2018	11800	10750	10350	11950	11800	13150	12650	34700	34700	44650	41300	47900	13000	12000	14950	14250
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
888	3/9/2021	12150	10550	10750	12350	12250	13850	13250	32500	32500	30250	47100	31400	15550	14300	16350	15900
889	6/9/2021	12150	10550	10750	12350	12250	13850	13250	31750	31750	39900	40350	31400	15550	14350	16350	15900
900	7/9/2021	12150	10550	10750	12350	12250	13850	13250	31500	31500	40300	48150	31400	15600	14400	16400	15900
901	8/9/2021	12150	10550	10750	12350	12250	13850	13250	31450	31450	40850	50000	31650	15600	14400	16400	15900
902	9/9/2021	12150	10550	10750	12350	12250	13850	13250	31700	31700	40750	48150	32350	15600	14400	16400	15900


903 rows \* 32 columns

Gambar 4. Hasil Pengumpulan Data


### B. Uji Normalitas Data

Uji normalitas data dilakukan dengan melakukan visualisasi grafik menggunakan distribusi normal untuk tiap harga bahan pokok. Setelah dilakukan visualisasi dan uji normalitas data pada semua harga bahan pokok, diperoleh 4 harga bahan pokok yang memiliki kurva normal yang berbentuk seperti lonceng. Hal ini menandakan bahwa keempat harga bahan pokok tersebut merupakan data yang berdistribusi normal. Pada penelitian ini memprediksi harga bahan pokok yang hanya memiliki kurva distribusi normal.


Pada Gambar 5 merupakan grafik distribusi normal pada harga beras kualitas bawah II, Gambar 6 merupakan grafik distribusi normal pada harga daging ayam ras segar, Gambar 7 merupakan grafik distribusi normal pada harga minyak goreng, dan Gambar 8 merupakan grafik distribusi normal pada harga minyak goreng curah.




Gambar 5. Kurva Distribusi Normal pada Harga Beras Kualitas Bawah II



Gambar 6. Kurva Distribusi Normal pada Harga Daging Ayam Ras Segar



Gambar 7. Kurva Distribusi Normal pada Harga Minyak Goreng



Gambar 8. Kurva Distribusi Normal pada Harga Minyak Goreng Curah

### C. Normalisasi

Tahap yang kedua pada *preprocessing data* adalah normalisasi data harga bahan pokok menggunakan metode *min max*. Hasil dari normalisasi data disajikan pada Tabel 1.

Tabel 1. Hasil Normalisasi Data

Data ke-	Normalisasi
1.	0.52727273
2.	0.52363636
3.	0.49818182
4.	0.50909091
5.	0.52
..	...
899.	0.36
900.	0.30545455
901.	0.28727273
902.	0.28363636
903.	0.30181818

### D. Segmentasi

Tahap terakhir pada *preprocessing data* adalah segmentasi. Pada penelitian ini segmentasi dilakukan sebagai uji coba untuk mengetahui apakah penggunaan banyaknya *timestep* mempengaruhi keakuratan pada model.

Hasil segmentasi pada Tabel 3 menggunakan *timestep* sebanyak 5 dan *output* atau target sebanyak 1. Pada penelitian ini menggunakan uji coba dengan *timestep* sebanyak 7, 10, dan 15 dengan *output* atau target yang digunakan yaitu 1 dan 5.

Tabel 2. Hasil Segmentasi

Timestep					Target
X1	X2	X3	X4	X5	Y1
0.527	0.524	0.498	0.509	0.52	0.538
0.524	0.498	0.509	0.52	0.538	0.553
0.498	0.509	0.52	0.538	0.553	0.553

### E. Pelatihan Model

Proses pelatihan pada model diawali dengan menentukan parameter nilai bobot pada tiap *gate* LSTM, yang telah ditentukan secara acak oleh *library Tensorflow*. Pada Gambar 9, disajikan jumlah total parameter yang digunakan pada model. Total parameter sebanyak 830 diperoleh dengan menjumlahkan dimensi *input*, banyaknya *unit* LSTM, banyaknya *gate* pada LSTM, dan dimensi *output*.

Model: "sequential\_1"

Layer (type)	Output Shape	Param #
lstm_3 (LSTM)	(None, 7, 10)	480
lstm_4 (LSTM)	(None, 5)	320
dense_1 (Dense)	(None, 5)	30
Total params: 830		
Trainable params: 830		
Non-trainable params: 0		

Gambar 9. Total Parameter pada Model

Total parameter didapatkan menggunakan persamaan 26. Dimana  $h$  adalah banyaknya dimensi *input*, dan  $x$  adalah banyaknya *feature*.

$$\text{Total Params} = 4 \times (h \times (h + x) + h) \quad (26)$$

Apabila diterapkan pada model dengan *neuron* pada *layer* LSTM pertama yaitu 10, maka didapatkan total parameter sebanyak 480.

$$\text{Total Param lstm}_3 = 4 \times (10 \times (10 + 1) + 10)$$

$$\text{Total Param lstm}_3 = 4(120)$$

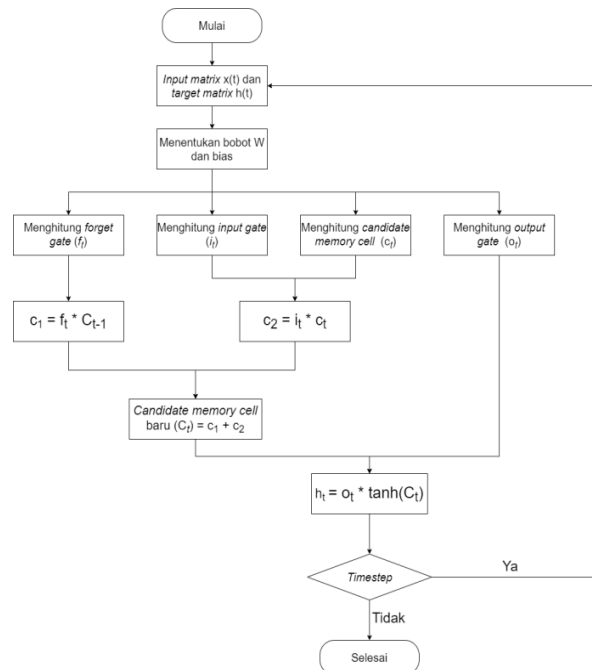
$$\text{Total Param lstm}_3 = 480$$

Perhitungan tersebut dilakukan juga untuk *layer* kedua serta pada *dense* layer. Ketiga *layer* tersebut dijumlahkan sehingga memperoleh total parameter keseluruhan yaitu 830.

Proses pelatihan dilakukan dengan beberapa eksperimen terhadap metode optimasi. Eksperimen dilakukan hingga memperoleh hasil evaluasi yang terbaik.


Tahapan perhitungan pada *layer* LSTM dapat dilihat pada Gambar 10, yang melalui 4 *gate* yaitu *forget gate*, *input gate*, kandidat *cell state*, dan *output gate*. Perhitungan pada LSTM menggunakan nilai bobot dan bias untuk diterapkan pada persamaan (15) sampai dengan persamaan (20) untuk tiap *gate* LSTM.

Pelatihan model dilakukan menggunakan data latih sesuai dengan banyaknya *batch size* dalam memperbarui nilai bobot. Bobot pada LSTM selama pelatihan akan diperbarui hingga mencapai nilai konvergen. Oleh karena itu, diterapkannya metode optimasi saat pelatihan model untuk mengoptimalkan bobot dalam mencari nilai lokal minima.



Gambar 10. Proses pada LSTM Layer [18]

Hasil pelatihan model pada harga daging ayam ras segar didapatkan seperti pada Gambar 11. Pada gambar tersebut, grafik yang berwarna biru merupakan data aktual dan data berwarna kuning merupakan data hasil prediksi setelah melalui proses pelatihan. Model memiliki kinerja yang sangat baik dalam memprediksi harga daging ayam ras segar. Hal ini dapat dilihat berdasarkan pola grafik yang hampir memiliki kesamaan.



Gambar 11. Perbandingan Data Hasil Training dengan Data Aktual

### F. Evaluasi Model

Hasil evaluasi yang diperoleh pada tiap harga bahan pokok memiliki perbedaan. Model yang memiliki hasil evaluasi terbaik berdasarkan uji coba menggunakan berbagai parameter, digunakan untuk memprediksi harga bahan pokok untuk 5 hari kedepan. Hasil evaluasi pada penelitian dijabarkan berdasarkan metode optimasi yang cocok diterapkan pada model LSTM. Evlauasi pada model menggunakan nilai RMSE dan  $r^2$  score.

#### 1) Harga Daging Ayam Ras Segar

Proses pelatihan dan pengujian model menggunakan 3 metode optimasi yaitu ADAM, AdaGrad dan RMSProp. Hasil yang diperoleh pada tiap metode optimasi terdapat perbedaan pada tiap parameter yang diterapkan untuk

melatih model. Pada penelitian ini, disajikan hasil uji coba hingga mendapatkan hasil evaluasi terbaik pada tiap metode optimasi dan jumlah komposisi pemisahan *dataset*.

#### a. ADAM

Tabel 3. Uji Coba pada Harga Daging Ayam Ras Segar dengan Metode Optimasi ADAM

<i>Learning Rate</i>	<i>Jumlah Epoch</i>	<i>Batch Size</i>	<i>Timestep</i>	<i>RMSE</i>	<i>R2 Score</i>
0.01	100	5	7	0.1235	0.2247
0.01	100	5	7	0.2729	0.2729
0.01	150	5	7	0.0497	0.1270
0.01	200	5	7	0.1297	0.1418
0.01	150	5	10	0.1150	0.3258
0.05	150	5	15	0.1506	-0.1569
0.05	100	5	15	0.1506	-0.1569
0.05	200	5	15	0.1410	-0.0133
0.0001	100	5	7	0.1217	0.2471

#### b. AdaGrad

Tabel 4. Uji Coba pada Harga Daging Ayam Ras Segar dengan Metode Optimasi AdaGrad

<i>Learning Rate</i>	<i>Jumlah Epoch</i>	<i>Batch Size</i>	<i>Timestep</i>	<i>RMSE</i>	<i>R2 Score</i>
0.01	100	5	7	0.1691	-0.1738
0.01	100	5	7	0.3160	-3.0977
0.01	150	5	7	0.1253	0.3560
0.01	200	5	7	0.0601	0.1514
0.01	150	5	10	0.1912	-0.5005
0.05	150	5	15	0.1878	-0.4471
0.05	100	5	15	0.1709	-0.1995
0.05	200	5	15	0.2005	-0.6499
0.0001	100	5	7	0.1509	0.063

#### c. RMSProp

Tabel 5. Uji Coba pada Harga Daging Ayam Ras Segar dengan Metode Optimasi RMSProp

<i>Learning Rate</i>	<i>Jumlah Epoch</i>	<i>Batch Size</i>	<i>Timestep</i>	<i>RMSE</i>	<i>R2 Score</i>
0.01	100	5	7	0.1026	0.5682
0.01	100	5	7	0.1253	0.3563
0.01	150	5	7	0.1099	0.5037
0.01	200	5	7	0.1059	0.5402
0.01	150	5	10	0.1055	0.5430
0.05	150	5	15	0.5282	0.1072
0.05	100	5	15	0.5698	0.1024
0.05	200	5	15	0.3222	0.1285
0.0001	100	5	7	0.1046	0.5506

Berdasarkan hasil uji coba menggunakan ketiga metode optimasi tersebut, didapatkan bahwa metode optimasi ADAM menghasilkan nilai evaluasi yang paling

baik. Hal ini dapat diketahui berdasarkan hasil evaluasi yang berwarna kuning pada masing-masing tabel yang merupakan model terbaik untuk tiap metode optimasi. Hasil evaluasi RMSE terendah yaitu 0.0497 dan *R2 Score* tertinggi yaitu sebesar 0.3258.

#### 2) Harga Beras Kualitas Bawah II

Pada percobaan yang telah dilakukan pada harga beras kualitas bawah II dengan parameter-parameter seperti *learning rate*, *batch size*, banyaknya LSTM layer, *epoch* dan *timestep*. Pada harga beras kualitas bawah II juga melakukan uji coba menggunakan 3 metode optimasi, yaitu ADAM, AdaGrda, dan RMSProp. Ketiga hasil uji coba disajikan pada Tabel 6 – 8.

#### a. ADAM

Tabel 6. Uji Coba pada Harga Beras Kualitas Bawah II dengan Metode Optimasi ADAM

<i>Learning Rate</i>	<i>Jumlah Epoch</i>	<i>Batch Size</i>	<i>Timestep</i>	<i>RMSE</i>	<i>R2 Score</i>
0.001	100	5	7	0.065	0.5262
0.0001	100	5	7	0.0846	0.1970
0.005	100	5	7	0.0719	0.4192
0.0005	100	5	7	0.0590	0.6087
0.001	100	10	7	0.0808	0.2674
0.001	100	15	7	0.0717	0.4224
0.001	100	32	7	0.0788	0.3037
0.001	100	64	7	0.1034	-0.1988
0.01	50	15	10	0.0888	0.0785
0.01	150	10	10	0.0914	0.024
0.01	200	5	10	0.1079	-0.36

#### b. AdaGrad

Tabel 7. Uji Coba pada Harga Beras Kualitas Bawah II dengan Metode Optimasi AdaGrad

<i>Learning Rate</i>	<i>Jumlah Epoch</i>	<i>Batch Size</i>	<i>Timestep</i>	<i>RMSE</i>	<i>R2 Score</i>
0.001	100	5	7	0.2866	-8.2106
0.0001	100	5	7	0.6469	-45.92
0.005	100	5	7	0.2197	-4.4122
0.0005	100	5	7	0.3637	-13.838
0.001	100	10	7	0.3827	-15.425
0.001	100	15	7	0.3697	-14.327
0.001	100	32	7	0.5146	-28.696
0.001	100	64	7	0.5847	-37.34
0.01	50	15	10	0.5697	-35.393
0.01	150	10	10	0.2827	-7.9637
0.01	200	5	10	0.3033	-9.7455

#### c. RMSProp

Tabel 8. Uji Coba pada Harga Beras Kualitas Bawah II dengan Metode Optimasi RMSProp

<i>Learning Rate</i>	<i>Jumlah Epoch</i>	<i>Batch Size</i>	<i>Timestep</i>	<i>RMSE</i>	<i>R2 Score</i>
----------------------	---------------------	-------------------	-----------------	-------------	-----------------



0.001	100	5	7	0.0668	0.4988
0.0001	100	5	7	0.0801	0.2795
0.005	100	5	7	0.0946	-0.005
0.0005	100	5	7	0.0772	0.3307
0.001	100	10	7	0.0647	0.2022
0.001	100	15	7	0.0628	0.5569
0.001	100	32	7	0.0829	0.2287
0.001	100	64	7	0.0728	0.4046
0.01	50	15	10	0.0718	0.3972
0.01	150	10	10	0.1063	-0.3210
0.01	200	5	10	0.1246	-0.8135

Berdasarkan uji coba menggunakan ketiga metode optimasi dalam pembaruan bobot, didapatkan hasil evaluasi terbaik yaitu menggunakan metode ADAM dengan nilai RMSE sebesar 0.0590 dan nilai *R2 Score* sebesar 0.6087. Perolehan model terbaik juga didukung oleh parameter lain yaitu *learning rate* sebesar 0.0005, jumlah *epoch* sebanyak 100 kali, *batch size* sebanyak 5, dan *timestep* sebanyak 7.

### 3) Harga Minyak Goreng

Seperti eksperimen yang dilakukan pada harga bahan pokok lainnya, pelatihan model pada harga minyak goreng menggunakan 3 metode optimasi dengan parameter-parameter lainnya. Model terbaik dalam memprediksi harga minyak goreng yaitu menggunakan metode RMSProp.

#### a. ADAM

Tabel 9. Uji Coba pada Harga Minyak Goreng dengan Metode Optimasi ADAM

<i>Learning Rate</i>	Jumlah Epoch	Batch Size	<i>Timestep</i>	RMSE	<i>R2 Score</i>
0.001	100	5	7	0.0551	0.6548
0.0001	100	5	7	0.0662	0.5029
0.005	100	5	7	0.1407	-1.2474
0.0005	100	5	7	0.0989	-0.1107
0.001	100	10	7	0.1027	-0.1969
0.001	100	15	7	0.1051	-0.2549
0.001	100	32	7	0.2484	-0.4811
0.001	100	64	7	0.1295	-0.9032
0.01	50	15	10	0.1385	-1.1759
0.01	150	10	10	0.0521	0.6789
0.01	200	5	10	0.1198	-0.6979

#### b. AdaGrad

Tabel 10. Uji Coba pada Harga Harga Minyak Goreng dengan Metode Optimasi AdaGrad

<i>Learning Rate</i>	Jumlah Epoch	Batch Size	<i>Timestep</i>	RMSE	<i>R2 Score</i>
0.001	100	5	7	0.5699	-35.837
0.0001	100	5	7	0.7946	-70.613

0.005	100	5	7	0.2635	-6.8788
0.0005	100	5	7	0.6117	-41.444
0.001	100	10	7	0.6289	-43.860
0.001	100	15	7	0.6917	-53.270
0.001	100	32	7	0.6970	-54.105
0.001	100	64	7	0.7177	-59.903
0.01	50	15	10	0.2806	-8.3137
0.01	150	10	10	0.5379	-33.204
0.01	200	5	10	0.5699	-35.837

#### c. RMSProp

Tabel 11. Uji Coba pada Harga Minyak Goreng dengan Metode Optimasi RMSProp

<i>Learning Rate</i>	Jumlah Epoch	Batch Size	<i>Timestep</i>	RMSE	<i>R2 Score</i>
0.001	100	5	7	0.1016	-0.1723
0.0001	100	5	7	0.1145	-0.4879
0.005	100	5	7	0.1244	-0.7568
0.0005	100	5	7	0.0818	0.2395
0.001	100	10	7	0.074	0.3772
0.001	100	15	7	0.1027	-0.1983
0.001	100	32	7	0.1319	-0.9744
0.001	100	64	7	0.1449	-1.3826
0.01	50	15	10	0.1318	-1.0552
0.01	150	10	10	0.065	0.4997
0.01	200	5	10	0.0495	0.3721

Berdasarkan hasil uji coba yang telah dilakukan, diperoleh hasil model terbaik pada tiap metode optimasi ditandai dengan warna kuning. Hasil evaluasi dari tiap metode optimasi dipilih yang terbaik, dan diperoleh yaitu menggunakan metode optimasi RMSProp dengan nilai RMSE terendah yaitu 0.0495 dan nilai *R2 Score* tertinggi yaitu sebesar 0.4997. Perolehan model terbaik tersebut juga dipengaruhi oleh parameter lainnya seperti *learning rate* yang digunakan yaitu sebesar 0.01, jumlah *epoch* yaitu sebanyak 200, *batch size* sebanyak 10, dan *timestep* sebesar 10.

### 4) Harga Minyak Goreng Curah

Hasil evaluasi pada harga minyak goreng curah yang didapatkan secara keseluruhan mengalami *overfitting*. Hal ini dikarenakan nilai *r2 score training* yang didapatkan jauh lebih tinggi daripada *r2 score testing*. Akan tetapi, terdapat satu metode optimasi yang dapat melatih model dengan baik yaitu ADAM. Penerapan metode optimasi ADAM dengan komposisi pemisahan data latih dan data uji sebanyak 80%:20% menghasilkan model terbaik dalam memprediksi harga minyak goreng curah.

#### a. ADAM

Tabel 12. Uji Coba pada Harga Minyak Goreng Curah dengan Metode Optimasi ADAM

<i>Learning</i>	Jumlah	Batch	<i>Timestep</i>	RMSE	<i>R2</i>
-----------------	--------	-------	-----------------	------	-----------

Rate	Epoch	Size			Score
0.001	100	5	7	0.0531	0.5308
0.0001	100	5	7	0.0855	-0.2170
0.005	100	5	7	0.0785	-0.0241
0.0005	100	5	7	0.0852	-0.2073
0.001	100	10	7	0.1178	-1.3093
0.001	100	15	7	0.0907	-0.3709
0.001	100	32	7	0.1303	-1.8227
0.001	100	64	7	0.1195	-1.3730
0.01	50	15	10	0.0778	-0.0253
0.01	150	10	10	0.1205	-1.4620
0.01	200	5	10	0.0932	-0.4734

#### b. AdaGrad

Tabel 13. Uji Coba pada Harga Harga Minyak Goreng Curah dengan Metode Optimasi AdaGrad

Learning Rate	Jumlah Epoch	Batch Size	Timestep	RMSE	R2 Score
0.001	100	5	7	0.4717	-35.984
0.0001	100	5	7	0.8530	-119.92
0.005	100	5	7	0.1625	-3.3917
0.0005	100	5	7	0.5853	-55.932
0.001	100	10	7	0.6241	-63.727
0.001	100	15	7	0.6995	-80.132
0.001	100	32	7	0.7161	-84.218
0.001	100	64	7	0.7575	-94.356
0.01	50	15	10	0.2825	-12.521
0.01	150	10	10	0.1508	-2.8519
0.01	200	5	10	0.1359	-2.1123

#### c. RMSProp

Tabel 14. Uji Coba pada Harga Minyak Goreng Curah dengan Metode Optimasi RMSProp

Learning Rate	Jumlah Epoch	Batch Size	Timestep	RMSE	R2 Score
0.001	100	5	7	0.0752	0.0589
0.0001	100	5	7	0.1473	-2.6076
0.005	100	5	7	0.0917	-0.3973
0.0005	100	5	7	0.0852	-0.2079
0.001	100	10	7	0.1070	-0.9047
0.001	100	15	7	0.0804	-0.0728
0.001	100	32	7	0.0799	-0.0611
0.001	100	64	7	0.1460	-2.5433
0.01	50	15	10	0.0687	0.1989
0.01	150	10	10	0.1887	-5.031
0.01	200	5	10	0.1404	-2.3381

Perolehan model terbaik pada harga minyak goreng curah diperoleh menggunakan metode ADAM dengan

hasil evaluasi RMSE terendah yaitu sebesar 0.0531 dan nilai  $R^2$  Score 1 sebesar 0.5308. parameter lainnya juga memiliki pengaruh terhadap model, seperti penggunaan *learning rate* sebesar 0.001, jumlah *epoch* sebanyak 100, *batch size* sebanyak 5, dan *timestep* sebesar 7.

#### G. Denormalisasi

Denormalisasi merupakan proses untuk mengembalikan nilai skala harga di rentang 0-1, menjadi skala normal seperti awal. Hasil denormalisasi data harga bahan pokok nasional untuk harga daging ayam ras segar dapat dilihat pada Tabel 15. Proses denormalisasi ini memiliki tujuan yaitu untuk memahami perbandingan antara hasil prediksi harga bahan pokok dengan harga aktual.

Tabel 15. Hasil Denormalisasi Data

Data ke-	Normalisasi	Denormalisasi
1.	0.52727273	34800
2.	0.52363636	34750
3.	0.49818182	34400
4.	0.50909091	34550
5.	0.52	34700
..	...	...
899	0.36	32500
900.	0.30545455	31750
901.	0.28727273	31500
902.	0.28363636	31450
903.	0.30181818	31700

#### H. Prediksi

Prediksi pada 4 harga bahan pokok dilakukan untuk 5 hari kedepan. Tahapan prediksi ini menggunakan model terbaik berdasarkan optimalisasi menggunakan 3 algoritma gradien. Prediksi dilakukan menggunakan data 7 hari terakhir pada harga bahan pokok. Apabila tanggal terakhir pada *dataset* adalah 9 September 2021, maka prediksi dilakukan untuk tanggal 10 September 2021- 14 September 2021.

##### 1) Prediksi Harga Daging Ayam Ras Segar

Pada harga daging ayam ras segar diperoleh hasil prediksi untuk 5 hari kedepan menggunakan model terbaik yang didapatkan saat pelatihan maupun pengujian model. Model yang diterapkan yaitu menggunakan metode optimasi ADAM.

Tabel 16. Hasil Prediksi 5 Hari Kedepan Pada Harga Daging Ayam Ras Segar

Tanggal	Data Prediksi	Data Aktual	Selisih ( $\Delta$ )
10 September 2021	Rp. 31881,576	Rp. 34800	Rp. 2918.424
11 September 2021	Rp. 31745,646	Rp. 34800	Rp. 3054.354
12 September 2021	Rp. 31687,746	Rp. 34800	Rp. 3112.254
13 September 2021	Rp. 31720,531	Rp. 34800	Rp. 3079.469

14 September 2021	Rp. 31737,473	Rp. 34800	Rp. 3062,527
		Rata-rata $\Delta$	Rp. 3046,132

Tabel 16 merupakan hasil prediksi untuk 5 hari kedepan pada harga daging ayam ras segar. Selisih antara data prediksi dengan data aktual yang didapatkan cukup tinggi, yaitu dengan rata-rata selisih nya yaitu sebesar Rp. 3046,132.

#### 2) Prediksi Harga Beras Kualitas Bawah II

Prediksi harga beras kualitas bawah II untuk 5 hari kedepan menggunakan model terbaik hasil percobaan yang telah dilakukan sebelumnya. Model terbaik yang didapatkan yaitu dengan menerapkan metode ADAM.

Tabel 17. Hasil Prediksi 5 Hari Kedepan Pada Harga Beras Kualitas Bawah II

Tanggal	Data Prediksi	Data Aktual	Selisih ( $\Delta$ )
10 September 2021	Rp. 10674,821	Rp. 10350	Rp. 324,821
11 September 2021	Rp. 10675,616	Rp. 10300	Rp. 375,616
12 September 2021	Rp. 10689,728	Rp. 10300	Rp. 389,728
13 September 2021	Rp. 10678,179	Rp. 10300	Rp. 378,179
14 September 2021	Rp. 10701,63	Rp. 10300	Rp. 401,63
		Rata-rata $\Delta$	Rp. 374,916

Disisi lain, juga terdapat beberapa parameter yang digunakan seperti *learning rate* sebesar 0.01, *epoch* sebanyak 50, *batch size* sebanyak 15, *timestep* sebanyak 10, dan LSTM layer sebanyak 3 layer. Penggunaan *timestep* sebanyak 10, hal ini menandakan bahwa untuk memprediksi harga beras kualitas bawah II menggunakan 10 hari terakhir. Pada Tabel 10, diperoleh bahwa model telah berhasil memprediksi harga beras kualitas bawah II. Hal ini dapat dilihat bahwa rata-rata selisih antara data prediksi dengan data aktual cukup kecil yaitu sekitar Rp. 374,916.

#### 3) Prediksi Harga Minyak Goreng

Prediksi pada harga minyak goreng diperoleh menggunakan model LSTM dengan algoritma optimasi yaitu RMSProp yang mana komposisi data latih dan data uji sebesar 90%:10%. Selisih yang diperoleh pada prediksi harga minyak goreng untuk 5 hari kedepan cukup kecil dengan rata-rata sebesar Rp. 832,286. Hal ini dapat dikatakan bahwa model yang diterapkan untuk memprediksi harga beras kualitas bawah II, telah berhasil dalam melakukan prediksi. Parameter lain yang diterapkan pada model yaitu penggunaan *learning rate* sebesar 0.01, *epoch* sebanyak 200, *batch size* sebanyak 5, dan *timestep* sebanyak 10. Pada penelitian ini menggunakan 10 hari terakhir untuk memprediksi harga beras kualitas bawah II 5 hari kedepan

Tabel 18. Hasil Prediksi 5 Hari Kedepan Pada Harga Minyak Goreng

Tanggal	Data Prediksi	Data Aktual	Selisih ( $\Delta$ )
10 September 2021	Rp. 15236,485	Rp. 16000	Rp. 763,515

11 September 2021	Rp. 15216,937	Rp. 16050	Rp. 833,063
12 September 2021	Rp. 15181,22	Rp. 16050	Rp. 868,78
13 September 2021	Rp. 15189,637	Rp. 16050	Rp. 860,363
14 September 2021	Rp. 15218,408	Rp. 16050	Rp. 831,592
		Rata-rata $\Delta$	Rp. 832,286

#### 4) Prediksi Harga Minyak Goreng Curah

Hasil prediksi pada harga minyak goreng curah menggunakan model LSTM dengan algoritma optimasi yaitu ADAM yang mana komposisi data latih dan data uji sebesar 80%:20%. Parameter lain yang digunakan seperti *learning rate* sebesar 0.001, *epoch* sebanyak 100, *batch size* sebanyak 5, dan *timestep* sebanyak 7. Sehingga untuk memprediksi harga minyak goreng curah menggunakan harga 7 hari sebelumnya untuk mendapatkan hasil prediksi 5 hari kedepan.

Hasil prediksi yang diperoleh yaitu memiliki rata-rata selisih yang cukup tinggi yaitu sebesar Rp. 1537,872. Hal ini disebabkan karena beberapa hasil evaluasi yang didapatkan pada model terjadi *overfitting* sehingga berpengaruh terhadap hasil prediksi.

Tabel 19. Hasil Prediksi 5 Hari Kedepan Pada Harga Minyak Goreng Curah

Tanggal	Data Prediksi	Data Aktual	Selisih ( $\Delta$ )
10 September 2021	Rp. 13839,805	Rp. 15400	Rp. 1560,195
11 September 2021	Rp. 13949,736	Rp. 15450	Rp. 1500,264
12 September 2021	Rp. 13996,565	Rp. 15450	Rp. 1453,435
13 September 2021	Rp. 13846,157	Rp. 15450	Rp. 1603,843
14 September 2021	Rp. 13883,008	Rp. 15450	Rp. 1566,992
		Rata-rata $\Delta$	Rp. 1537,872

## IV. KESIMPULAN

Kesimpulan yang diperoleh berdasarkan penelitian yang telah dilakukan yaitu pada harga daging ayam ras segar didapatkan model terbaik dengan metode optimasi ADAM dengan hasil evaluasi RMSE sebesar 0.0937 dan *R2 score* sebesar 0.5949. Pada harga beras kualitas bawah II diperoleh model terbaik yaitu dengan metode optimasi ADAM dengan hasil evaluasi RMSE sebesar 0.0492 dan *R2 score* sebesar 0.8852. Pada harga minyak goreng diperoleh model terbaik yaitu menggunakan metode RMSProp dengan hasil evaluasi RMSE sebesar 0.0313 dan *r2 score* sebesar 0.7492. Sedangkan pada harga minyak goreng curah diperoleh model terbaik yaitu menggunakan metode ADAM dengan hasil evaluasi RMSE sebesar 0.0531 dan *R2 score* sebesar 0.5308.

## DAFTAR PUSTAKA

- [1] F. N. Sadiyah, "DAMPAK PANDEMI COVID-19 TERHADAP PERTUMBUHAN EKONOMI DAN PERDAGANGAN KOMODITAS PERTANIAN DI Indonesia," *J. Ekon. Pertan. dan Agribisnis*, vol. 5, no. 3, pp. 950–961, 2021, [Online]. Available: <https://doi.org/10.21776/ub.jepa.2021.005.03.30>.
- [2] Y. L. Sukestiyarno, "Identifikasi Publikasi Dosen dalam Mewujudkan Internasionalisasi Universitas Negeri Semarang Menggunakan Neural Network," *J. Mipa*, vol. 41, no. 2, pp. 121–133, 2018.
- [3] F. Nur Hadiansyah, "Prediksi Harga Cabai dengan Menggunakan pemodelan Time Series ARIMA," *Indones. J. Comput.*, vol. 2, no. 1, p. 71, 2017, doi: 10.21108/indoic.2017.2.1.144.
- [4] M. Hussein and Y. Azhar, "Prediksi Harga Minyak Dunia Dengan Metode Deep Learning," vol. 6, no. 1, 2021.
- [5] A. S. Bayangkari Karno, "Analisis Data Time Series Menggunakan LSTM (Long Short Term Memory) Dan ARIMA (Autocorrelation Integrated Moving Average) Dalam Bahasa Python.," *Ultim. InfoSys J. Ilmu Sist. Inf.*, vol. 11, no. 1, pp. 1–7, 2020, doi: 10.31937/si.v9i1.1223.
- [6] S. Sen, D. Sugiarto, and A. Rochman, "Komparasi Metode Multilayer Perceptron (MLP) dan Long Short Term Memory (LSTM) dalam Peramalan Harga Beras," *Ultimatics*, vol. XII, no. 1, p. 35, 2020.
- [7] H. S. Husain, "Distribusi Normal Multivariat," *J. Mat. Stat. dan Komputasi*, vol. 14, no. 2, p. 143, 2018, doi: 10.20956/jmsk.v14i2.3553.
- [8] P. Ferdiansyah, R. Indrayani, and S. Subektiningsih, "Analisis Manajemen Bandwidth Menggunakan Hierarchical Token Bucket Pada Router dengan Standar Deviasi," *J. Nas. Teknol. dan Sist. Inf.*, vol. 6, no. 1, pp. 38–45, 2020, doi: 10.25077/teknosi.v6i1.2020.38-45.
- [9] M. A. Dwiyanto, C. E. Djamal, and A. Maspupah, "Prediksi Harga Saham menggunakan Metode Recurrent Neural Network," *Semin. Nas. Apl. Teknol. Inf.*, pp. 33–38, 2019.
- [10] A. A. Lydia and F. S. Francis, "Adagrad-An Optimizer for Stochastic Gradient Descent," *Int. J. Inf. Comput. Sci.*, vol. 6, no. 5, pp. 566–568, 2019, [Online]. Available: <http://ijics.com>.
- [11] I. Hanif, "Klasifikasi Perintah Bahasa Natural Menggunakan Global Vectors for Word Representations (GloVe), Convolutional Neural Networks, dan Teknik Transfer Learning ....," 2018, [Online]. Available: [https://repository.its.ac.id/52194/1/05111440000177-Undergraduate\\_Thesis.pdf](https://repository.its.ac.id/52194/1/05111440000177-Undergraduate_Thesis.pdf).
- [12] S. Zahara, Sugianto, and M. B. Ilmiddafiq, "Prediksi Indeks Harga Konsumen Menggunakan Metode Long Short Term Memory (LSTM) Berbasis Cloud Computing," *Resti*, vol. 1, no. 1, pp. 19–25, 2017.
- [13] N. Nugroho, Y. Rahmanto, D. Alita, J. Z. Pagar Alam, and L. Ratu, "Software Development Sistem Informasi Kursus Mengemudi (Kasus: Kursus Mengemudi Widi Mandiri)," *J. Sains Komput. Inform. (J-SAKTI)*, vol. 5, no. 1, pp. 328–336, 2021, [Online]. Available: <http://tunasbangsa.ac.id/ejurnal/index.php/jsakti/article/view/325>.
- [14] R. Pamusti, "Studi Kinerja Algoritma Optimasi Pada Metode Quantum Clustering Dengan Kernel Entropy Component Analysis," 2018.
- [15] D. P. Kingma and J. L. Ba, "Adam: A method for stochastic optimization," *3rd Int. Conf. Learn. Represent. ICLR 2015 - Conf. Track Proc.*, pp. 1–15, 2015.
- [16] W. Y. Rusyida and V. Y. Pratama, "Prediksi Harga Saham Garuda Indonesia di Tengah Pandemi Covid-19 Menggunakan Metode ARIMA," *Sq. J. Math. Math. Educ.*, vol. 2, no. 1, p. 73, 2020, doi: 10.21580/square.2020.2.1.5626.
- [17] F. Rustam *et al.*, "COVID-19 Future Forecasting Using Supervised Machine Learning Models," *IEEE Access*, vol. 8, pp. 101489–101499, 2020, doi: 10.1109/ACCESS.2020.2997311.
- [18] J. F. Ritchie Ng, "Deep Learning Wizard," Apr. 2019, doi: 10.5281/ZENODO.2644957.